PARTIE A : deux caractères qualitatifs

I Rappel : médiane, quartiles et boîte à moustaches

Rappel. Soit une série de n valeurs rangées dans l'ordre croissant.

- La **médiane** Me partage la série en deux groupes de même effectif : si n est impair, c'est la valeur **centrale** ; si n est pair, c'est la **demi-somme des deux valeurs centrales**.
- Le **premier quartile** Q_1 est la plus petite valeur de la série telle qu'au moins **25 %** des valeurs lui soient inférieures ou égales. Le **troisième quartile** Q_3 est la plus petite valeur telle qu'au moins **75 %** des valeurs lui soient inférieures ou égales.
- L'**étendue** est max − min ; l'**écart interquartile** est $Q_3 - Q_1$.
- Une **boîte à moustaches** résume la série par cinq nombres : min, Q_1, Me, Q_3, max.

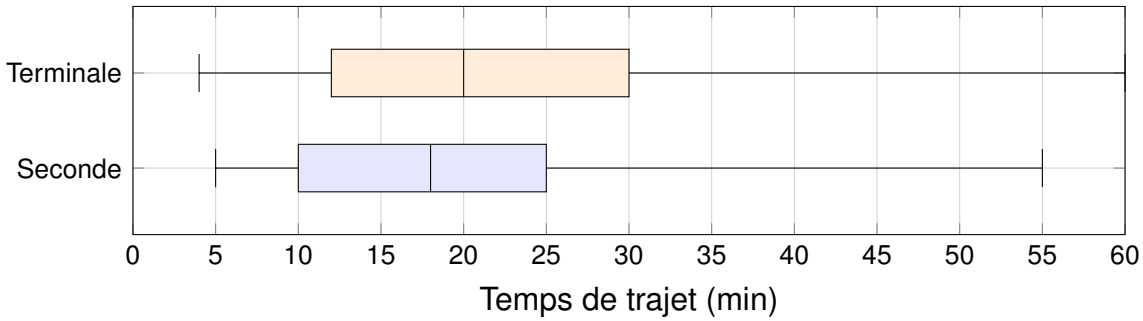
Exemple

Temps de trajet (en minutes) de 15 élèves de seconde, rangés dans l'ordre croissant :

5, 8, 10, 10, 12, 15, 15, 18, 20, 22, 25, 25, 30, 40, 55.

a) Déterminer Me, Q_1 et Q_3. $n = 15$ est impair : Me est la 8e valeur, soit 18 min. $15 \times 0{,}25 = 3{,}75$, donc Q_1 est la 4e valeur, soit 10 min. $15 \times 0{,}75 = 11{,}25$, donc Q_3 est la 12e valeur, soit 25 min.

b) Construire la boîte à moustaches de cette série. Les élèves de terminale ont : min = 4, $Q_1 = 12$, $Me = 20$, $Q_3 = 30$, max = 60 ; ajouter leur boîte.



c) Comparer les deux distributions. La médiane est plus élevée en terminale (20 min contre 18 min), ainsi que l'écart interquartile (18 min contre 15 min) : les trajets y sont plus longs et plus

dispersés.

II Lire un fichier de données

Activité

Une enquête est menée auprès de 24 élèves d'un lycée. Pour chacun, on relève son *genre*, son *niveau*, son *mode de transport* principal pour venir au lycée, et le fait qu'il pratique ou non un *sport en club*. *(Données fictives. Onglet* `Lycee24` *du fichier tableur.)*

N°	*Genre*	*Niveau*	*Transport*	*Sport*
1	F	2nde	Bus	Oui
2	M	2nde	Voiture	Non
3	F	1re	Vélo/marche	Oui
4	M	Tle	Voiture	Oui
5	F	2nde	Bus	Non
6	M	1re	Bus	Oui
7	F	Tle	Voiture	Non
8	M	2nde	Vélo/marche	Oui
9	F	1re	Bus	Non
10	M	Tle	Bus	Oui
11	F	2nde	Voiture	Non
12	M	1re	Vélo/marche	Non

N°	*Genre*	*Niveau*	*Transport*	*Sport*
13	F	Tle	Bus	Oui
14	F	1re	Voiture	Oui
15	M	2nde	Bus	Non
16	F	2nde	Vélo/marche	Oui
17	M	Tle	Voiture	Non
18	F	1re	Bus	Oui
19	M	1re	Voiture	Non
20	F	Tle	Vélo/marche	Non
21	M	2nde	Bus	Oui
22	F	2nde	Voiture	Oui
23	M	Tle	Bus	Non
24	F	1re	Vélo/marche	Non

a) Que représente une ligne du tableau ? une colonne ? Combien y a-t-il d'élèves ?

b) Quels sont les caractères étudiés ? Donner leurs modalités.

c) Combien d'élèves de première viennent en bus ?

d) Combien d'élèves sont des filles **ou** pratiquent un sport en club ?

e) Combien d'élèves ne viennent pas en voiture ?

Définition

Une **population** est l'ensemble des **individus** (ou unités statistiques) étudiés ; le nombre d'individus est l'**effectif total** N.

Un **caractère** (ou variable) est une propriété observée sur chaque individu. Ses différentes valeurs

possibles sont ses **modalités**.

- Un caractère est **qualitatif** si ses modalités ne sont pas des nombres, ou si calculer avec elles n'a pas de sens.
- Un caractère est **quantitatif** si ses valeurs sont des **nombres** avec lesquels on peut calculer (somme, moyenne...).

Dans un **fichier de données**, chaque **ligne** correspond à un individu et chaque **colonne** à un caractère ; la première ligne contient le nom des caractères.

Remarque. Un numéro d'élève, un code postal ou un numéro de département sont écrits avec des chiffres, mais ce sont des caractères **qualitatifs** : leur somme n'a aucun sens. Le niveau (2nde, 1re, Tle) est qualitatif, avec des modalités ordonnées.

Filtres ET, OU, NON

Soient A et B deux conditions portant sur les caractères d'un fichier.

- « A **ET** B » : individus qui vérifient **les deux conditions à la fois**.
- « A **OU** B » : individus qui vérifient **au moins une des deux conditions** (le « ou » est **inclusif**).
- « **NON** A » : individus qui **ne vérifient pas** la condition A.

Propriété

$\text{Eff}(A \text{ OU } B) = \text{Eff}(A) + \text{Eff}(B) - \text{Eff}(A \text{ ET } B)$ et $\text{Eff}(\text{NON } A) = N - \text{Eff}(A)$.

Méthode (Compter avec des filtres au tableur)**.** Les données sont dans les lignes 2 à 241 ; colonnes : A = N°, B = Genre, C = Niveau, D = Transport, E = Sport.

- ET : `=NB.SI.ENS(C2:C241;"Tle";D2:D241;"Voiture")`
- NON : `=NB.SI.ENS(D2:D241;"<>Bus")`
- OU : on **additionne** les deux effectifs puis on **retire** les individus comptés deux fois (avec `NB.SI` et `NB.SI.ENS`).

Selon le logiciel, `NB.SI.ENS` s'appelle aussi `COUNTIFS` (Excel anglais, Google Sheets). On peut aussi utiliser le filtre automatique et lire le nombre de lignes affichées.

Exemple

Dans le fichier de l'activité 1, on note A : « être en première » et B : « venir en bus ».

a) Déterminer Eff(A), Eff(B) et Eff(A ET B). Eff(A) = 8, Eff(B) = 10, Eff(A ET B) = 3.

b) En déduire Eff(A OU B) et Eff(NON B). Eff(A OU B) = $8+10-3=15$; Eff(NON B) = $24-10=14$.

EXERCICE 1

Dans l'onglet `Lycee240` du fichier tableur (240 élèves, mêmes caractères que l'activité 1 ; *données fictives*) :

a) Donner le nombre d'individus, de caractères, et la nature de chaque caractère.

b) Écrire la formule du tableur puis donner l'effectif : (i) « Tle ET Voiture » ; (ii) « 2nde OU Vélo/marche » ; (iii) « NON Bus » ; (iv) « 1re ET (Voiture OU Bus) ».

c) Combien d'élèves vérifient « 2nde ET 1re » ? Pourquoi ce « ET » ne correspond-il pas à ce que l'on dit dans la vie courante ?

III Tableau croisé d'effectifs

Activité

On reprend le fichier de l'activité 1 pour croiser le *genre* et la pratique d'un *sport en club*.

	Sport : oui	*Sport : non*	*Total*
Filles	**7**	**6**	**13**
Garçons	**5**	**6**	**11**
Total	**12**	**12**	**24**

a) Compléter le tableau à l'aide du fichier.

b) Combien de filles pratiquent un sport ? Que représente le nombre 13 ? le nombre 24 ?

Définition

Un **tableau croisé d'effectifs** (ou tableau à double entrée) indique, pour chaque couple de modalités (une pour chaque caractère), le nombre d'individus qui les possèdent : c'est l'**effectif croisé**.

Les totaux des lignes et des colonnes sont les **effectifs marginaux**. Le total général est l'effectif total N : on le retrouve en additionnant **les totaux des lignes**, ou **les totaux des colonnes**.

Méthode (Construire un tableau croisé au tableur)**. Étape 1.** **Lister les modalités** : celles du premier caractère en lignes, celles du second en colonnes.

Étape 2. Dans chaque case, compter les individus qui ont **les deux modalités** :

```
=NB.SI.ENS($C$2:$C$241;$G3;$D$2:$D$241;H$2)
```

Les signes **$** fixent les plages, ce qui permet de **recopier** la formule dans tout le tableau.

Étape 3. Calculer les **totaux** avec `=SOMME(...)`.

Étape 4. Contrôler que le total général est égal à N, le nombre de lignes du fichier.

Autre méthode : Insertion → Tableau croisé dynamique (Données → Tableau croisé dynamique) : caractère 1 en lignes, caractère 2 en colonnes, valeurs = nombre de $N°$.

Exemple

Dans l'onglet `Lycee240`, construire le tableau croisé du *niveau* et du *mode de transport*. *(Données fictives.)*

	Voiture	*Bus*	*Vélo/marche*	*Total*
Seconde	**18**	**45**	**27**	**90**
Première	**28**	**32**	**20**	**80**
Terminale	**35**	**21**	**14**	**70**
Total	**81**	**98**	**61**	**240**

Lecture : **28** élèves de première viennent en voiture ; **98** élèves viennent en bus.

EXERCICE 2

Dans un lycée de 200 élèves, 60 % sont des filles. Parmi les filles, 45 % pratiquent un sport en club ; parmi les garçons, 55 %. *(Données fictives.)*

a) Compléter le tableau croisé.

	Sport : oui	*Sport : non*	*Total*
Filles			
Garçons			
Total			200

b) Quelle proportion des élèves du lycée pratique un sport en club ?

c) Quelle proportion des sportifs sont des filles ?

IV Fréquences marginales et conditionnelles

Activité

Dans un échantillon de 1 000 personnes, on croise l'*âge* et le fait d'être *vacciné contre la grippe* lors de la dernière campagne. *(Données fictives, proportions inspirées des bilans de couverture vaccinale de Santé publique France.)*

	Vacciné	*Non vacciné*	*Total*
65 ans et plus	165	135	300
Moins de 65 ans	105	595	700
Total	270	730	1 000

a) Quelle proportion de l'échantillon est vaccinée ?

b) Parmi les personnes de 65 ans et plus, quelle proportion est vaccinée ?

c) Parmi les personnes vaccinées, quelle proportion a 65 ans et plus ?

d) Les réponses b) et c) sont-elles égales ? Pourquoi ?

e) Comparer la proportion de vaccinés chez les 65 ans et plus et chez les moins de 65 ans. Que peut-on en conclure ?

Définition

Soit un tableau croisé d'effectif total N.

- Une **fréquence marginale** est le quotient d'un **effectif marginal** par **l'effectif total** N.
- Une **fréquence conditionnelle** est la proportion d'une modalité **parmi** les individus qui ont une modalité donnée de l'autre caractère : on divise l'effectif croisé par **l'effectif marginal de la population de référence** (celle qui suit « parmi »).

Méthode (Calculer une fréquence conditionnelle)**. 1.** Repérer la **population de référence** : c'est celle qui suit « parmi ».

2. Son **effectif marginal** (total de sa ligne ou de sa colonne) est le **dénominateur**.

3. Le **numérateur** est l'effectif croisé correspondant à la modalité cherchée.

4. Les fréquences conditionnelles d'une même ligne (ou colonne) ont pour somme 100 %.

Exemple

Avec le tableau de l'activité 3, compléter les fréquences conditionnelles **par ligne** puis **par colonne** (arrondies à 0,1 %).

Par ligne	*Vacciné*	*Non vacciné*	*Total*
65 ans et plus	**55 %**	**45 %**	100 %
Moins de 65 ans	**15 %**	**85 %**	100 %

Par colonne	*Vacciné*	*Non vacciné*
65 ans et plus	**61,1 %**	**18,5 %**
Moins de 65 ans	**38,9 %**	**81,5 %**
Total	100 %	100 %

Phrases de lecture : « **55 %** des personnes de 65 ans et plus sont vaccinées » (par ligne) ; « **61,1 %** des personnes vaccinées ont 65 ans et plus » (par colonne).

Lecture et interprétation

Pour savoir si deux caractères semblent liés, on compare les **fréquences conditionnelles** d'un caractère selon les modalités de l'autre. Si elles sont (presque) **égales**, il n'y a pas de lien apparent

; si elles **diffèrent nettement**, il y a un lien apparent entre les deux caractères.

Remarque. Un lien observé dans un tableau ne prouve pas une relation de cause à effet. Par ailleurs, une fréquence conditionnelle par ligne et la fréquence conditionnelle par colonne **ne sont pas égales** en général. Cette distinction sera essentielle en probabilités.

Exemple

Avec le tableau croisé niveau × transport, calculer les fréquences conditionnelles **par ligne**, puis interpréter.

	Voiture	*Bus*	*Vélo/marche*	*Total*
Seconde	**20 %**	**50 %**	**30 %**	100 %
Première	**35 %**	**40 %**	**25 %**	100 %
Terminale	**50 %**	**30 %**	**20 %**	100 %

Interprétation : la part des élèves venant en voiture augmente avec le niveau (20 %, 35 %, 50 %) alors que la part du bus diminue : le niveau et le mode de transport sont liés dans ce fichier.
Parmi les élèves venant en bus, quelle est la part des élèves de seconde ? $45/98 \approx 45{,}9\,\%$.

EXERCICE 3

On a interrogé 2 000 personnes de 25 à 54 ans sur leur *diplôme* et leur *situation* sur le marché du travail. *(Données fictives, ordres de grandeur inspirés de l'Insee.)*

	En emploi	*Au chômage*	*Inactif*	*Total*
Inférieur au bac	504	84	112	
Baccalauréat	410	45	45	
Bac +2 ou plus	720	40	40	
Total				

a) Compléter les totaux. Quelle est la fréquence marginale des personnes en emploi ?

b) Pour chaque diplôme, calculer la fréquence des personnes en emploi, au chômage, inactives.

c) Comparer les trois situations. Que peut-on dire du lien entre diplôme et situation ?

d) Parmi les personnes au chômage, quelle proportion a un diplôme inférieur au bac ? Pourquoi ce résultat ne répond-il pas à la question « le chômage touche-t-il davantage les moins diplômés ? »

EXERCICE 4

Vrai ou faux ? Justifier avec le tableau de l'activité 3 (vaccination).

a) « 30 % des personnes de l'échantillon ont 65 ans et plus. »

b) « 55 % des personnes vaccinées ont 65 ans et plus. »

c) « Parmi les moins de 65 ans, 85 % ne sont pas vaccinés. »

d) « Les personnes vaccinées sont en majorité des moins de 65 ans. »

V Représentations graphiques d'un tableau croisé

Activité

À partir du tableau croisé niveau × transport (onglet `Lycee240`), construire au tableur :
(1) un diagramme en barres *juxtaposées* ; **(2)** un diagramme en barres *empilées* ; **(3)** un diagramme en barres empilées *à* 100 % (en fréquences par niveau) ; **(4)** un diagramme *circulaire* des modes de transport des élèves de première.
Pour chacun : quelle information lit-on le plus facilement ?

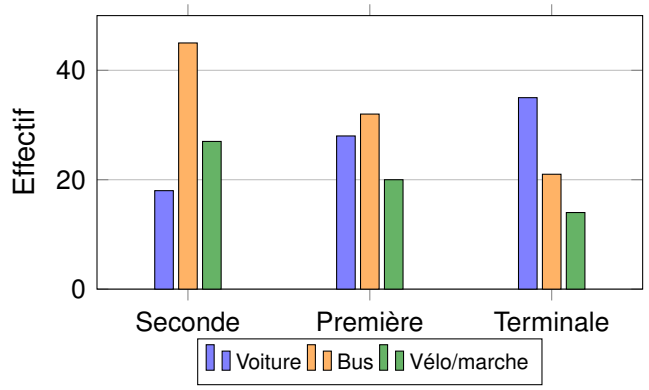
Définition

- Un diagramme en **barres juxtaposées** met côte à côte les effectifs (ou fréquences) des modalités d'un caractère pour chaque modalité de l'autre : il permet de **comparer les valeurs**.
- Un diagramme en **barres empilées** empile les modalités dans une seule barre par groupe : il montre le **total** de chaque groupe et sa composition.
- Un diagramme en barres empilées **à** 100 % représente les **fréquences conditionnelles par ligne** : il permet de comparer des groupes d'**effectifs différents**.
- Un diagramme **circulaire** représente la répartition d'**un seul caractère** dans **une seule population** : l'angle d'un secteur est proportionnel à sa fréquence, soit fréquence × 360°.

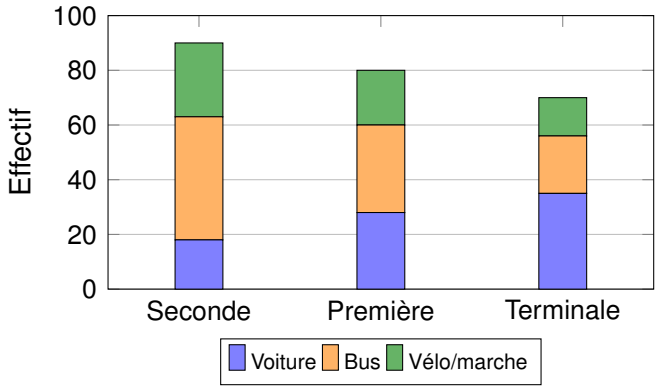
Exemple

Représentations du tableau croisé niveau × transport.

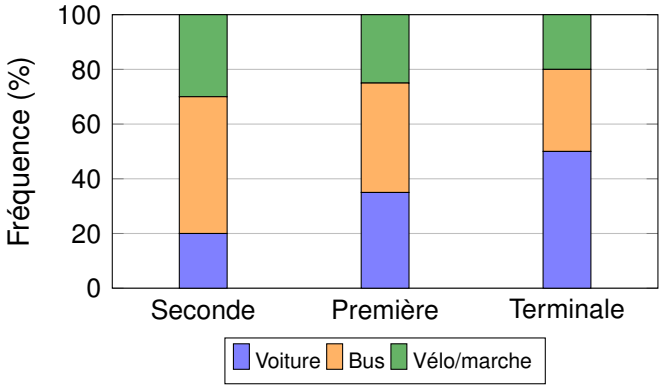
(1) Juxtaposées

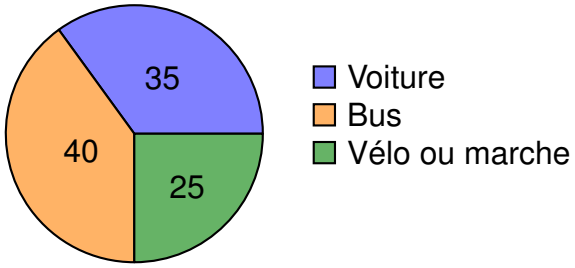


(2) Empilées



(3) Empilées à 100 %





(4) Élèves de première

Angles du diagramme (4) : voiture 35 % × 360° = 126° ; bus 40 % × 360° = 144° ; vélo/marche 25 % × 360° = 90°.

Choix : pour comparer le poids de la voiture selon le niveau, on utilise le diagramme (3), à 100 % : les groupes n'ont pas le même effectif (90, 80, 70).

Méthode (Choisir et critiquer un diagramme)**. 1.** Que veut-on comparer : des **effectifs** ou des **fréquences** ? des groupes de tailles **différentes** ?

2. Un diagramme circulaire ne convient pas pour comparer plusieurs populations, ni avec plus de **5 ou 6** modalités.

3. Vérifier : titre, légende, unités, **axe des ordonnées partant de** 0, somme des parts égale à 100 %.

EXERCICE 5

Dans le parc de résidences principales (en milliers), on croise le *type de logement* et le *mode de chauffage principal*. *(Données fictives, ordres de grandeur inspirés des enquêtes logement et de l'ADEME.)*

	Électricité	*Gaz*	*Fioul*	*Autre*	*Total*
Maison	5 880	5 040	2 520	3 360	
Appartement	5 280	6 600	660	660	
Total					

a) Compléter les totaux. Quelle est la fréquence marginale des logements chauffés au gaz ?

b) Calculer, pour chaque type de logement, la répartition des modes de chauffage (fréquences par ligne).

c) Parmi les logements chauffés au fioul, quelle proportion sont des maisons ? Parmi les maisons, quelle proportion est chauffée au fioul ?

d) Au tableur, construire le diagramme en barres empilées à 100 % par type de logement, puis un diagramme circulaire pour les maisons. Calculer les angles des secteurs.

EXERCICE 6

Une enquête sur 1 500 personnes croise la *tranche d'âge* et la fréquence d'usage des *réseaux sociaux*. *(Données fictives, ordres de grandeur inspirés des baromètres du numérique.)*

	Quotidien	*Occasionnel*	*Jamais*	*Total*
15 – 24 ans	270	24	6	300
25 – 44 ans	420	120	60	600
45 ans et plus	270	150	180	600
Total	960	294	246	1 500

a) Calculer les fréquences conditionnelles par ligne.

b) Quel diagramme choisir pour comparer l'usage quotidien selon l'âge ? Le construire.

c) Un article titre : « Les 15 – 24 ans ne représentent que 28,1 % des utilisateurs quotidiens : ils boudent les réseaux sociaux. » Retrouver ce nombre et expliquer l'erreur de raisonnement.

d) Un élève propose un unique diagramme circulaire à neuf secteurs pour tout le tableau. Pourquoi est-ce inadapté ?

PARTIE B : deux caractères quantitatifs

VI Nuage de points et point moyen

Activité

La concentration de l'air en dioxyde de carbone (CO_2) est mesurée à l'observatoire de Mauna Loa (Hawaï). On note t le nombre d'années écoulées depuis 2000 et y la concentration moyenne annuelle en ppm (parties par million). *(Données réelles : NOAA Global Monitoring Laboratory, onglet `CO2`.)*

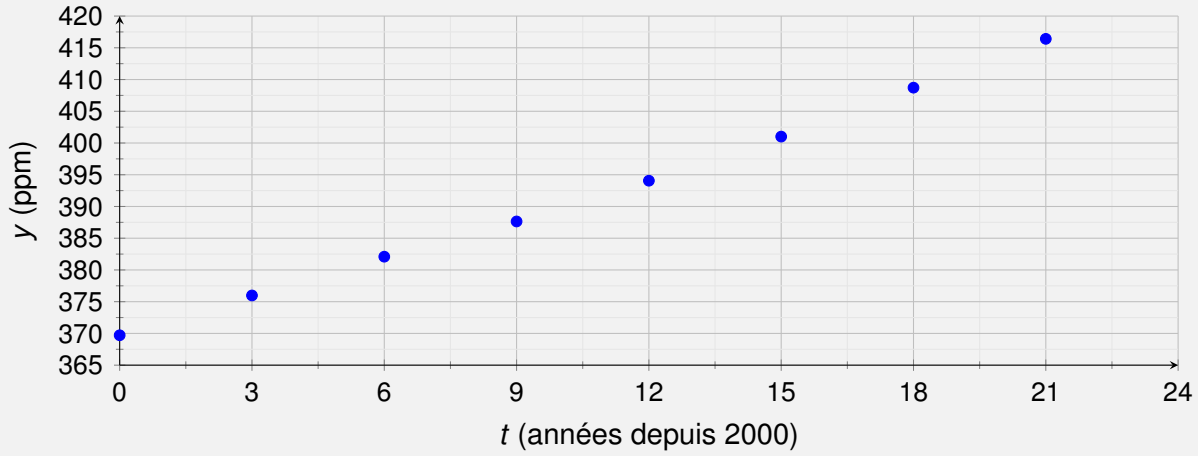
Année	2000	2003	2006	2009	2012	2015	2018	2021
t	0	3	6	9	12	15	18	21
y (ppm)	369,71	375,98	382,09	387,64	394,06	401,01	408,72	416,41

a) Représenter ces données par un nuage de points $(t\,;y)$.

b) Comment évolue y quand t augmente ? Les points semblent-ils alignés ?

c) Estimer « à l'œil » la concentration en 2007 et en 2030.

d) Comment obtenir une estimation plus précise, et plus reproductible d'une personne à l'autre ?



Définition

Une **série statistique à deux caractères quantitatifs** associe à chaque individu deux nombres $(x_i\,;y_i)$. Son **nuage de points** est l'ensemble des points $M_i(x_i\,;y_i)$ dans un repère. Quand un caractère peut être vu comme expliquant l'autre (par exemple le temps), on le place en **abscisse**.

Remarque. Le nuage peut avoir une forme **allongée croissante**, **allongée décroissante**, **aucune forme visible**, ou une forme **courbe**. Au tableur, on choisit « Nuage de points (XY) » et non « Courbe » : ce dernier traite les abscisses comme des étiquettes régulièrement espacées. Pour des années, on peut faire un **changement d'origine** (t = année $-$ 2000) afin de calculer avec de petits nombres.

Définition

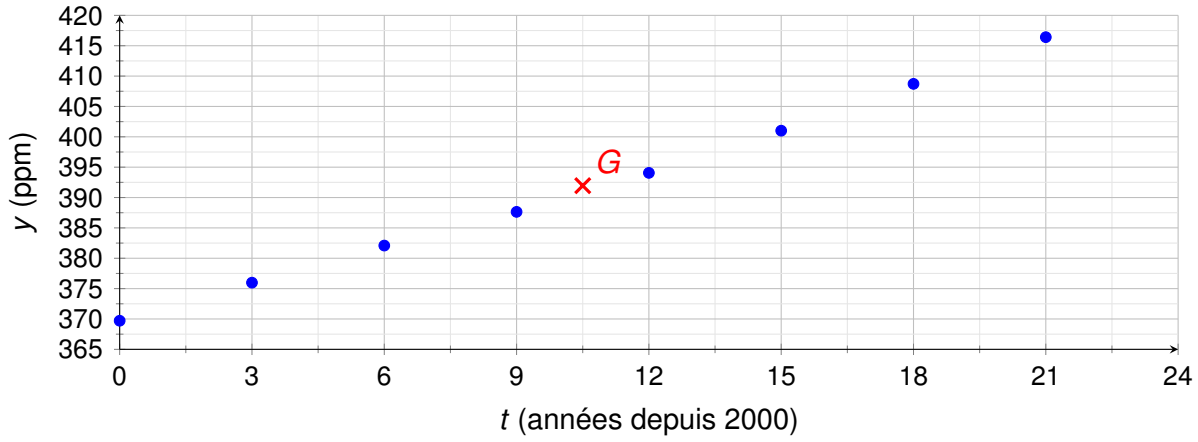
Le **point moyen** du nuage est le point $G(\overline{x}\,;\overline{y})$ avec

$$\overline{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} \quad \text{et} \quad \overline{y} = \frac{y_1 + y_2 + \cdots + y_n}{n}.$$

Au tableur : `=MOYENNE(plage des x)` et `=MOYENNE(plage des y)`.

Exemple

Calculer le point moyen G du nuage des concentrations de CO_2 et le placer sur le nuage. $\overline{t} = \dfrac{0+3+6+9+12+15+18+21}{8} = \dfrac{84}{8} = 10{,}5$; $\overline{y} = \dfrac{3\,135{,}62}{8} \approx 391{,}95$. Donc $G(10{,}5\,;391{,}95)$.



VII Ajustement affine : au jugé et droite de Mayer

Définition

Ajuster un nuage de points par une droite, c'est choisir une droite d d'équation $y = ax + b$ qui passe « au plus près » des points. Il existe plusieurs méthodes (**au jugé**, droite de **Mayer**, **moindres carrés**) : elles donnent des droites voisines lorsque le nuage est bien **allongé**.

Méthode (Ajustement au jugé)**. 1.** Placer le **point moyen** G.

2. Tracer à la règle une droite passant par G, « au plus près » des points, avec à peu près **autant de points de chaque côté**.

3. Lire les coordonnées de deux points A et B de la droite, puis calculer $a = \dfrac{y_B - y_A}{x_B - x_A}$ et b avec $b = y_A - a\,x_A$.

Exemple

Pour le CO_2, on trace la droite passant par $G(10{,}5\,;391{,}95)$ et par le point $A(0\,;369)$. Déterminer son équation réduite. $a = \dfrac{391{,}95 - 369}{10{,}5 - 0} \approx 2{,}19$ et $b = 369$. L'équation est $y \approx 2{,}19\,t + 369$: la concentration augmente d'environ 2,19 ppm par an.

Méthode (Droite de Mayer)**.** On suppose que le nuage compte n points, avec n pair.

1. Ranger les points par abscisses croissantes puis les partager en **deux groupes de même effectif** $\frac{n}{2}$.

2. Calculer le point moyen G_1 du **premier groupe** et le point moyen G_2 du **second groupe**.

3. La **droite de Mayer** est la droite (G_1G_2) : $a = \dfrac{y_{G_2} - y_{G_1}}{x_{G_2} - x_{G_1}}$, puis $b = y_{G_1} - a\,x_{G_1}$ (en gardant les valeurs non arrondies).

Remarque. Si n est impair, on convient d'attribuer la valeur centrale à l'un des deux groupes. Avec deux groupes de même effectif, le point G est le milieu de $[G_1G_2]$: la droite de Mayer **passe par** G.

Exemple

Déterminer la droite de Mayer du nuage de CO_2 ($n = 8$). Groupe 1 ($t = 0;3;6;9$) : $\overline{t}_1 = 4{,}5$; $\overline{y}_1 = \dfrac{369{,}71 + 375{,}98 + 382{,}09 + 387{,}64}{4} = \dfrac{1\,515{,}42}{4} = 378{,}855$, d'où $G_1(4{,}5\,;378{,}855)$.

Groupe 2 ($t = 12;15;18;21$) : $\overline{t}_2 = 16{,}5$; $\overline{y}_2 = \dfrac{1\,620{,}2}{4} = 405{,}05$, d'où $G_2(16{,}5\,;405{,}05)$.

$a = \dfrac{405{,}05 - 378{,}855}{16{,}5 - 4{,}5} = \dfrac{26{,}195}{12} \approx 2{,}18$ et $b = 378{,}855 - 2{,}1829 \times 4{,}5 \approx 369{,}03$.

Droite de Mayer : $y \approx 2{,}18\,t + 369{,}03$. Contrôle : $2{,}1829 \times 10{,}5 + 369{,}03 \approx 391{,}95$, ordonnée de G.

EXERCICE 7

Espérance de vie à la naissance des hommes en France métropolitaine. On pose t = année $-$ 2000. *(Données réelles : Insee, 2019 valeur provisoire, onglet `EspVie`.)*

Année	2000	2005	2010	2015	2019
t	0	5	10	15	19
y (années)	75,3	76,8	78,0	79,0	79,8

a) Représenter le nuage de points.

b) Calculer les coordonnées du point moyen G.

c) Ajustement au jugé : tracer la droite passant par G et par le point $A(0\,;75{,}3)$; déterminer son équation réduite.

d) Estimer l'espérance de vie des hommes en 2012. Est-ce une interpolation ?

VIII Ajustement affine : moindres carrés

Définition

L'**écart vertical** d'un point $M_i(x_i\,;y_i)$ à une droite d d'équation $y = ax+b$ est $|y_i - (ax_i + b)|$. La droite des **moindres carrés** (ou droite de régression de y en x) est la droite pour laquelle la **somme des carrés** des écarts verticaux est **minimale**. Aucun calcul à la main n'est demandé : on utilise un outil.

Propriété (admise)

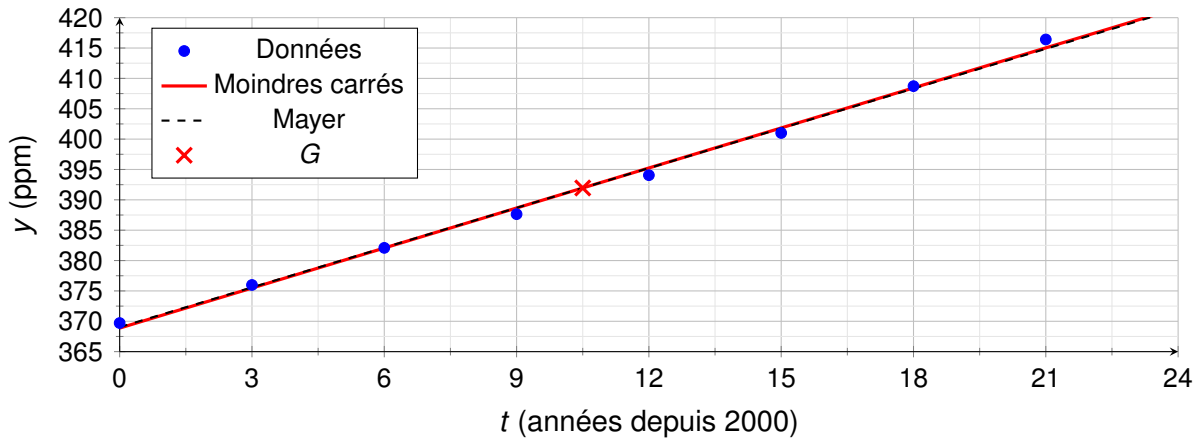
La droite des moindres carrés passe par le **point moyen** G.

Méthode (Obtenir la droite des moindres carrés)**.**

- **Tableur :** `=PENTE(plage des y;plage des x)` donne a ; `=ORDONNEE.ORIGINE(plage des y;plage des x)` donne b. Ou : clic droit sur un point du nuage → « Ajouter une courbe de tendance » → linéaire, avec affichage de l'équation.
- **TI-83/84 :** listes `L1` (x) et `L2` (y), puis `STAT` → `CALC` → `LinReg(ax+b)`.
- **Casio Graph :** `STAT` → saisie des listes → `CALC` → `REG` → `X` → `ax+b`.
- **NumWorks :** application Statistiques → onglet Graphique → Régression → **affine**.

Exemple

Déterminer, avec le tableur ou la calculatrice, la droite des moindres carrés du nuage de CO_2, puis la comparer à la droite de Mayer. On obtient $a \approx 2{,}20$ et $b \approx 368{,}88$: $y \approx 2{,}20\,t + 368{,}88$. Vérification : la droite passe par G ($2{,}1975 \times 10{,}5 + 368{,}878 \approx 391{,}95$). Mayer : $y \approx 2{,}18\,t + 369{,}03$; les deux droites sont très proches. Le coefficient directeur indique une augmentation moyenne d'environ 2,2 ppm par an.



EXERCICE 8

Consommation d'électricité en France un jour d'hiver, en fonction de la température moyenne de la journée. *(Données fictives, d'après l'ordre de grandeur d'environ* 2,4 *GW par degré donné par RTE ; onglet* `Electricite`*.)*

x : température (°C)	0	2	4	6	8	10	12	14
y : consommation (GW)	83	79	73	69	63	60	54	50

a) Représenter le nuage de points. Quelle est son allure ?

b) Calculer les coordonnées du point moyen G.

c) Déterminer la droite de Mayer (arrondir a et b à 10^{-2}).

d) Déterminer la droite des moindres carrés avec un outil numérique.

e) Interpréter le coefficient directeur dans le contexte.

f) Estimer la consommation pour une température moyenne de 5 °C.

IX Interpolation, extrapolation et regard critique

Définition

Soit une droite d'ajustement d'équation $y = ax+b$ et $[x_{\min}\,;x_{\max}]$ l'intervalle des abscisses observées.

- **Interpoler**, c'est estimer y pour une valeur de x **comprise dans** $[x_{\min}\,;x_{\max}]$.
- **Extrapoler**, c'est estimer y pour une valeur de x **en dehors de** cet intervalle.

Méthode (Estimer, puis juger)**. 1.** Pour estimer y connaissant x : **remplacer** x dans l'équation. Pour estimer x connaissant y : **résoudre** l'équation $ax + b = y$.
2. Dire si l'on **interpole ou extrapole**.
3. Regard critique : l'estimation est d'autant moins fiable que l'on s'**éloigne** des valeurs observées ; le résultat est-il **possible** dans le contexte (valeur négative, limite physique) ? Le nuage est-il vraiment **allongé** ? La tendance peut-elle changer ?

Remarque. Deux grandeurs qui évoluent ensemble ne sont pas forcément liées par une relation de cause à effet : les ventes de glaces et le nombre de baignades évoluent ensemble parce que les deux dépendent de la température.

Exemple

On utilise la droite des moindres carrés du CO_2 : $y \approx 2{,}2\,t + 368{,}88$ (valeurs non arrondies conservées).

a) Estimer la concentration en 2007. Interpolation ou extrapolation ? $t = 7$: $y \approx 384{,}3$ ppm. Comme $7 \in [0\,;21]$, c'est une interpolation.

b) En quelle année la concentration atteindrait-elle 450 ppm ? On résout $2{,}2\,t + 368{,}88 = 450$, soit $t \approx 36{,}9$: vers l'année 2037 (extrapolation).

c) La valeur réelle mesurée en 2023 est 421,08 ppm. Que donne la droite ? Commenter, puis estimer la concentration en 2050. $t = 23$: $y \approx 419{,}4$ ppm, soit un écart d'environ 1,7 ppm (0,4 %) : l'extrapolation à court terme est fiable. En 2050 ($t = 50$), on obtient $\approx 478{,}8$ ppm : cette extrapolation est plus lointaine donc moins sûre ; de plus la croissance annuelle s'est accélérée depuis 2000, la valeur réelle pourrait être différente.

Exemple

Temps du vainqueur du 100 m masculin aux Jeux olympiques. On pose t = année-1980. *(Données réelles, onglet `100m` ; les Jeux de Tokyo ont eu lieu en 2021.)*

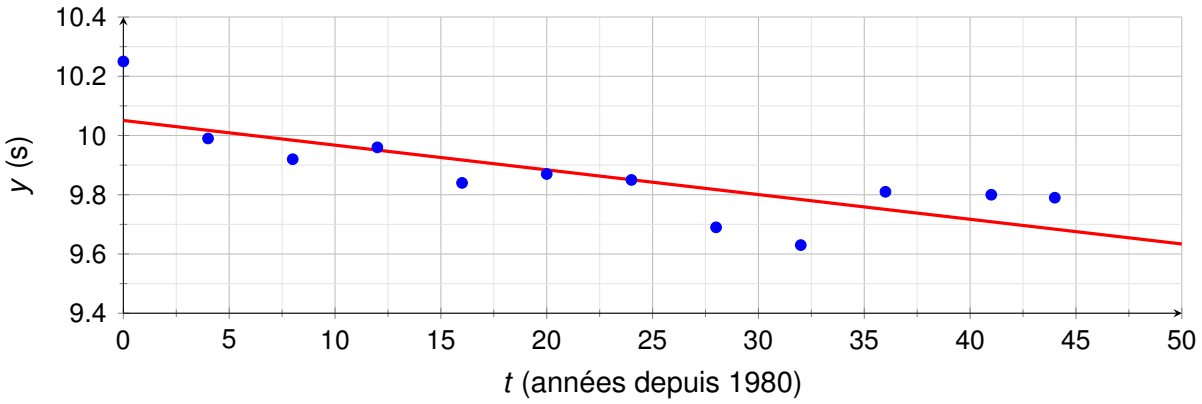
Année	1980	1984	1988	1992	1996	2000	2004	2008	2012	2016	2021	2024
t	0	4	8	12	16	20	24	28	32	36	41	44
y (s)	10,25	9,99	9,92	9,96	9,84	9,87	9,85	9,69	9,63	9,81	9,80	9,79

La droite des moindres carrés, obtenue au tableur, a pour équation $y \approx -0{,}0083\,t + 10{,}05$.

a) Interpréter le coefficient directeur. Le temps du vainqueur diminue en moyenne d'environ 0,008 s par an (environ 0,03 s par olympiade).

b) Estimer le temps du vainqueur en 2028, en 2100, puis en 2500. Ces estimations sont-elles vraisemblables ? 2028 : $t = 48$, $y \approx 9{,}65$ s ; 2100 : $t = 120$, $y \approx 9{,}05$ s ; 2500 : $t = 520$, $y \approx 5{,}7$ s. Le record du monde est de 9,58 s ; un temps de 5,7 s est impossible. L'estimation pour 2028 est plausible, celle de 2100 douteuse, celle de 2500 absurde.

c) Expliquer pourquoi la droite ne permet pas de prévoir le futur lointain. Une droite décroissante finit par donner un temps nul puis négatif (ici vers l'an 3 190). Or il existe une limite physiologique : la tendance ralentit. Le modèle affine n'est valable que près des valeurs observées.



EXERCICE 9

Prix d'une voiture d'occasion selon son âge. *(Données fictives, onglet* `VoitureOcc.`*)*

x : âge (années)	1	2	3	4	5	6	7	8
y : prix (k€)	21,0	18,6	16,9	14,4	12,6	10,9	8,1	6,5

a) Représenter le nuage. Calculer G.

b) Déterminer la droite de Mayer (arrondir à 10^{-2}).

c) Avec un outil numérique, déterminer la droite des moindres carrés.

d) Estimer le prix d'une voiture de 3,5 ans. Interpolation ou extrapolation ?

e) À partir de quel âge le prix estimé passe-t-il sous 5 k€ ?

f) Quel prix la droite donne-t-elle pour une voiture de 12 ans ? Commenter.

EXERCICE 10

Distance d'arrêt d'un véhicule selon sa vitesse. *(Données fictives, d'après le modèle « distance de réaction + distance de freinage » ; onglet* `Freinage.`*)*

x : vitesse (km/h)	30	50	70	90	110	130
y : distance d'arrêt (m)	13	27	45	67	93	123

a) Représenter le nuage. Les points semblent-ils alignés ?

b) Déterminer la droite des moindres carrés (valeurs non arrondies conservées). Calculer l'écart vertical $y_i - (ax_i + b)$ pour chaque point.

c) Que remarque-t-on sur le signe de ces écarts ? Que peut-on en conclure sur la pertinence d'un ajustement affine ?

d) Estimer la distance d'arrêt à 20 km/h avec cette droite. Commenter.